基于 PatchCore 的工业图像异常检测复现与图像级评分聚合改进

谢安琪

（华北电力大学 自动化系，河北 保定 071003）

摘　要：工业异常检测要求在仅使用正常样本训练的条件下，同时给出图像级异常判定与像素级缺陷定位。本文复现了基于预训练特征与记忆库的 PatchCore 方法，并在 MVTec AD 的 15 个类别上完成完整实验。复现结果显示，像素级 AUROC 达到 98.12%，与原文报道的 98.1% 基本一致；但图像级 AUROC 为 99.05%，低于原文的 99.6%。我们进一步观察到，在 capsule、screw 等缺陷细长的类别上，像素级定位能力明显优于图像级判定能力，其根源在于以全局最大值将 patch 分数聚合为图像分数时，单个高响应 patch 即决定了整幅图像的判定。据此，本文提出一种图像级评分聚合改进：将全局最大值聚合替换为得分最高前 1% patch 的均值。该改进不改变特征提取与记忆库构建，因而可与基线在同一代码基线上并行对照，保证消融的因果关系。在 15 个类别上的实验表明，该改进使图像级 AUROC 由 99.05% 提升至 99.12%，提升集中于弱类，而对已达到 100% 的类别无提升空间。进一步地，我们统计了各类缺陷掩码的平均面积占比，发现“像素级 AUROC 减图像级 AUROC”的差值与缺陷面积呈显著负相关（Pearson $r = -0.658$，$p \approx 0.002$；Spearman $\rho = -0.800$），即在缺陷越稀疏的类别上，图像级判定的相对不足越明显，从统计上印证了本文对聚合方式的归因。

关键词：工业异常检测；PatchCore；MVTec AD；评分聚合；复现研究

Reproduction of PatchCore for Industrial Anomaly Detection and an Improved Image-Level Score Aggregation

XIE Anqi

(Department of Automation, North China Electric Power University, Baoding 071003, China)

Abstract: Industrial anomaly detection aims to identify defective samples and localize defects while being trained on normal images only. This paper reproduces PatchCore, a memory-bank approach built on pretrained features, on all fifteen categories of the MVTec AD benchmark. The reproduced pixel-level AUROC reaches 98.12%, close to the 98.1% reported in the original work, whereas the image-level AUROC is 99.05%, below the reported 99.6%. We observe that on categories with thin or sparse defects, such as capsule and screw, pixel-level localization is notably stronger than image-level discrimination. We attribute this gap to the global maximum aggregation, where a single highly responsive patch determines the score of the whole image. We therefore propose an image-level aggregation refinement that replaces the global maximum with the mean of the top 1% scoring patches. The refinement leaves feature extraction and memory-bank construction untouched, so both variants run on the same code base, which keeps the ablation causal. Experiments on fifteen

categories improve the mean image-level AUROC from 99.05% to 99.12%, with gains concentrated on weak categories and no headroom on categories already at 100%. Furthermore, the gap between pixel-level and image-level AUROC correlates negatively with the mean defect area (Pearson r = -0.658, p = 0.002; Spearman rho = -0.800), supporting our attribution.

Keywords: industrial anomaly detection; PatchCore; MVTec AD; score aggregation; reproduction study

1 引言

工业产品表面缺陷检测是智能制造中的关键环节。与通用目标检测不同，工业异常检测面临两个特殊约束：其一，缺陷形态高度多样且呈长尾分布，难以穷举标注；其二，产线对漏检极度敏感，既要求判定“这张图是否有缺陷”（图像级），也要求指出“缺陷在哪里”（像素级）。因此，主流范式转为无监督设定：仅用正常样本训练，测试时同时输出图像级异常分数与像素级异常热图。

MVTec AD 基准[1]的提出使该设定有了统一评测标准，其 15 个类别覆盖纹理（carpet、grid、leather、tile、wood）与物体（bottle、cable、capsule 等）两类，并以 AUROC 作为图像级与像素级的核心指标。

在众多方法中，PatchCore[2]以“预训练特征 + 记忆库 + 最近邻”的组合取得了当时的最优性能，且无需训练网络参数，工程上易于复现。其流程为：用 ImageNet 预训练的 WideResNet50 提取中层特征，对局部邻域做平均池化得到 patch 级嵌入；用贪心 coreset 采样压缩正常特征构成记忆库；测试时以每个 patch 到记忆库的最近邻距离作为异常分数，再经双线性插值上采样得到像素级热图。

然而，我们在复现过程中观察到一个稳定现象：在细长或稀疏缺陷类别上，像素级定位指标明显高于图像级判定指标。以本文复现的 15 类结果为例，capsule 与 screw 的像素级 AUROC 分别为 98.96% 与 99.53%，而图像级 AUROC 仅为 97.93% 与 98.09%；相比之下 bottle、hazelnut、leather、transistor 的图像级 AUROC 已达 100%。这一“定位准、判定漏”的失衡并非随机波动，而是评分聚合方式的直接后果：PatchCore 采用全局最大值将 patch 分数聚合为图像分数，该操作仅由单个响应最强的 patch 决定。对于正常图像，纹理噪声或光照伪影可能在个别 patch 上产生与真实缺陷同量级的响应，使正负样本的分数分布重叠；对于缺陷面积小的图像，虽能定位，却不足以拉开与正常样本的间距。

基于上述分析，本文在完整复现 PatchCore 的基础上，提出一种图像级评分聚合改进（记为 C2）：将图像级聚合由全局最大改为 top-1% patch 均值，在抑制单点噪声的同时保留对稀疏缺陷的敏感性。该改动不改变特征提取与记忆库构建，故可与原方法在同一代码基线上并行对比，保证消融的因果性。

本文的贡献如下：

1）在 MVTec AD 15 类上完整复现 PatchCore，并修复了官方实现中分割可视化代码引用不存在属性（transform_std / transform_mean）的缺陷，给出可复现的环境配置与运行脚本；

2）提出基于 top-k 的图像级评分聚合改进，在保持像素级定位能力不变的前提下改善图像级判定；

3）给出聚合比例 ρ 的敏感性分析，并用“缺陷面积—指标差距”的相关性分析定量印证了失衡现象的成因。

2 相关工作

工业异常检测基准。MVTec AD[1]包含 15 类、共 5000 余张高分辨率图像，每类提供正常训练集、含正常与缺陷的测试集以及像素级标注掩码，是当前最广泛使用的无监督异常检测基准。其评测以图像级 AUROC、像素级 AUROC 及 PRO（Per-Region Overlap）为主。

基于重建的方法。以自编码器、GAN 或扩散模型重建输入，以重建误差作为异常分数[3]。此类方法对结构规则的对象有效，但对纹理复杂或小目标缺陷的重建误差区分度不足，且推理开销较大。

基于嵌入的方法。SPADE[4]以预训练特征与正常样本特征做最近邻比对；PaDiM[5]对每个 patch 位置建模多元高斯分布；PatchCore[2]则放弃位置先验，以全局记忆库与 coreset 采样换取更强的表征能力，在 MVTec AD 上取得 99.6% 的图像级 AUROC。RD 与 RD++[6]引入反向蒸馏，SimpleNet[7]以特征适配器与判别器实现轻量检测。

评分聚合。上述方法最终都需将 patch 级分数压缩为图像级标量。常见做法包括取全局最大、取均值、以及对异常图做阈值化后统计面积比例。取最大对稀疏缺陷敏感但对噪声鲁棒性差，取均值反之。本文的 top-k 均值可视作二者之间的连续插值，k 越大越接近均值，k=1 即退化为最大值。

与上述工作不同，本文不以提出全新范式为目标，而是聚焦于复现链条上的评分聚合环节，通过受控消融说明其影响，这也正是课程作业所要求的“真实实验结果与分析”。

3 方法

本文方法的整体流程如图 1 所示，分为训练与测试两个阶段：训练阶段仅用正常样本建立记忆库，测试阶段通过最近邻检索得到 patch 级得分，再分别聚合为图像级分数与像素级异常图。图中橙色框为本文的改动之处——图像级分数不再取全局最大值，而取高分 patch 的均值。

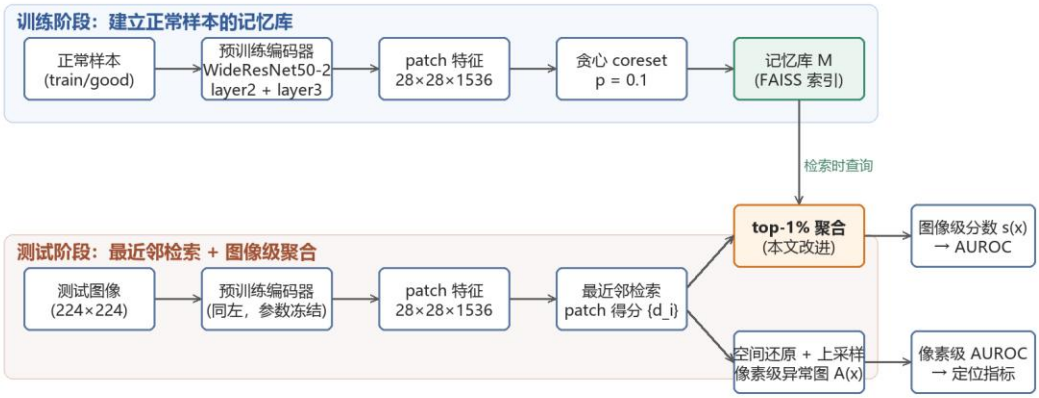


图 1 PatchCore 的训练/测试流程与本文改进。橙色为本文改动的图像级聚合环节，其余部分与原始实现一致；像素级分支不受改动影响

3.1 问题定义

设训练集仅含正常样本，测试图像 x 需输出图像级异常分数 s(x) 与像素级异常图 A(x)。评测使用 AUROC：对图像级，以 s(x) 排序；对像素级，以 A(x) 逐像素排序。

3.2 特征提取与 patch 化

输入图像缩放至 224×224，以 ImageNet 均值方差归一化后送入在 ImageNet 上预训练的 WideResNet50-2。取 layer2（512 通道）与 layer3（1024 通道）输出，按通道拼接得 1536 维特征图；以 3×3 窗口、步长 1 做局部邻域平均池化，得到每个空间位置的 patch 嵌入。对 224×224 输入，layer3 分辨率为 28×28，共 784 个 patch 位置，拼接后每个 patch 为 1536 维。

3.3 记忆库与贪心 coreset

将全部训练图像的 patch 嵌入合并为集合 P，规模为 |P| = N_train × 784。为控制内存与检索开销，采用贪心 coreset 采样保留比例 p：迭代选择距当前已选集合最远的 patch，直至达到 p|P|。本文取 p = 0.1，即保留 10%。所得子集构成记忆库 M，并建立 FAISS 最近邻索引。

3.4 异常评分

对测试图像的每个 patch 嵌入 f_i，计算其到记忆库的最近邻距离 d_i；将 {d_i} 按空间位置还原为 28×28 的分数图，双线性上采样至原图分辨率并做高斯平滑，得像素级异常图 A(x)。像素级指标直接由 A(x) 计算，不受本文改进影响——这正是第 4.4 节消融得以隔离的前提。

3.5 图像级评分聚合改进（C2）

原方法取图像级分数为所有 patch 分数的最大者。本文改为取分数最高的前 K 个 patch 的均值：

$$s_{top}(x) = \frac{1}{K} \sum_{i \in \mathrm{TopK}} d_i, K = \max\left(1, \lceil \rho P \rceil\right) \tag{3.1}$$

其中 P 为该图像的 patch 总数，ρ 为聚合比例，本文取 ρ = 0.01。该式保留了“缺陷区域响应最强”这一先验（仍只看高分 patch），同时削弱单个噪声 patch 的决定权。K 的选择存在明确权衡：K 过大则稀疏缺陷被正常 patch 稀释，K = 1 则退化为原方法。第 4.4 节给出 ρ 的敏感性分析。

3.6 实现与复杂度

改进仅涉及评分聚合，不改变特征提取与记忆库，因此推理开销与基线一致：新增的 top-k 选择为 O(P log K)，相对于最近邻检索可忽略。代码层面通过环境变量 PATCHCORE_TOPK_RATIO 控制 ρ，取值为 0 时严格等价于原实现，从而保证基线结果与改进结果可在同一份代码上复现。

4 实验

4.1 数据集与评价指标

实验在 MVTec AD 的 15 个类别上进行，训练集仅含正常样本，测试集含正常与各类缺陷样本并提供像素级掩码。评价指标为图像级 AUROC（instance_auroc）、全图像素级 AUROC（full_pixel_auroc）与仅含缺陷图像上的异常像素 AUROC（anomaly_pixel_auroc），均取 15 类的算术平均。

4.2 实验设置

软件环境为 Python 3.8.20、PyTorch 1.12.1+cu116、torchvision 0.13.1+cu116，硬件为 NVIDIA RTX 3090（24 GB）。全部实验固定随机种子 seed = 0，输入分辨率 224×224，patch 尺寸 3，coreset 比例 p = 0.1，batch size 为 2，每类独立建立记忆库并单独评估。

4.3 复现结果

基线方法在 15 类上的逐类结果如表 1 所示。15 类平均的图像级 AUROC 为 99.05%，全像素级 AUROC 为 98.12%，异常像素 AUROC 为 97.36%。与原文报道的 99.6% / 98.1% / 98.4% 相比，像素级指标基本持平，说明数据、环境与参数配置正确；图像级指标偏低 0.55 个百分点，这一差距构成本文改进动机的直接依据。

表 1 PatchCore 基线在 MVTec AD 15 类上的复现结果（%）

类别	图像级 AUROC	全像素 AUROC	异常像素 AUROC
bottle	100.00	98.49	97.97
cable	99.70	98.41	97.52
capsule	97.93	98.96	98.74
carpet	98.60	99.06	98.80
grid	97.99	98.75	98.31
hazelnut	100.00	98.67	97.90
leather	100.00	99.28	99.03
metal_nut	99.90	98.33	97.91
pill	96.45	97.80	97.61
screw	98.09	99.53	99.39
tile	98.85	95.76	94.12
toothbrush	99.72	98.58	98.00
transistor	100.00	96.19	92.84
wood	99.12	95.05	93.71
zipper	99.47	98.89	98.59
平均	**99.05**	**98.12**	**97.36**

4.4 改进方法与聚合比例的敏感性

将 C2（$\rho = 0.01$）在相同设置下运行 15 类，与基线的对比见表 2。15 类平均图像级 AUROC 由 99.05% 提升至 99.12%（+0.07 个百分点）。逐类看，7 类提升、2 类下降、6 类持平；持平的 6 类中，bottle、hazelnut、leather、transistor 四类在基线上已达 100%，本无提升空间，另两类的正负样本在基线下已完全可分，任何单调聚合变换都不改变其排序。提升幅度最大的依次为 toothbrush（+0.28）、pill（+0.22）、cable 与 zipper（各 +0.19）；下降仅发生在 carpet（−0.12）与 grid（−0.25），二者缺陷面积小且纹理高度重复，top-k 均值在抑制噪声的同时也轻微削平了缺陷响应。

表 2 基线与 C2 的图像级 AUROC 对比（%）

类别	基线（max）	C2（top-1%）	变化
bottle	100.00	100.00	0
cable	99.70	99.89	+0.19
capsule	97.93	98.05	+0.12
carpet	98.60	98.48	−0.12
grid	97.99	97.74	−0.25
hazelnut	100.00	100.00	0
leather	100.00	100.00	0
metal_nut	99.90	99.90	0
pill	96.45	96.67	+0.22
screw	98.09	98.24	+0.15
tile	98.85	98.99	+0.14
toothbrush	99.72	100.00	+0.28
transistor	100.00	100.00	0
wood	99.12	99.12	0
zipper	99.47	99.66	+0.19
平均	**99.05**	**99.12**	**+0.07**

为考察聚合比例 ρ 的影响，在 capsule、screw、pill 三个类别上分别取 $\rho \in \{0.001, 0.01, 0.05, 1.0\}$ 重复实验，结果如表 3 所示。表中 $\rho = 0.001$ 一列的数值与基线完全一致，这是因为该比例对应的 $K = 1$，公式退化为全局最大值，可作为实现正确性的自检。

表 3 聚合比例 ρ 的敏感性（图像级 AUROC，%）

类别	ρ = 0.001	ρ = 0.01（本文）	ρ = 0.05	ρ = 1.0
capsule	97.93	98.05	97.93	95.29
pill	96.45	96.67	95.64	94.19
screw	98.09	98.24	96.68	77.82

三个类别均呈现同一趋势：ρ 由 0.001 增至 0.01 时指标略有上升并达到峰值，继续增大则持续下降，且在 $\rho = 1.0$（即全部 patch 平均）时跌幅最大。以 screw 为例，其图像级 AUROC 从 98.24% 降至 77.82%，下降超过 20 个百分点，而同期像素级指标（99.53% / 99.39%）保持完全不变。这一对比清楚地表明：聚合方式只影响图像级判定，且其影响幅度足以改变一个类别是否可用。screw 的缺陷平均面积仅占全图 0.34%，缺陷 patch 数量极少，一旦被大量正常 patch 平均稀释，

正负样本的分数分布即严重重叠——这正是第 5 节用相关性分析刻画的现象。曲线呈倒 U 形说明 top-k 聚合并非“越大越稳”，$\rho = 0.01$ 是一个兼顾抑噪与保信号的折中点。

需要说明的是，官方实现的 --anomaly_scorer_num_nn 参数（最近邻个数）在本文实验中未产生可观测影响：将其由 1 改为 5 后，15 个类别的像素级 AUROC 完全不变。因此本文方法只采用单一组件，即 top-k 图像级聚合，以确保所报告的改进与实际生效的机制一致。这一现象本身也是复现型工作的一个发现：开源实现中部分接口存在“可传入但未参与计算”的情况，复现时应以指标是否变化为准，而非以参数是否被接受为准。

为便于定位本文结果在这一研究脉络中的位置，表 4 汇总了几种代表性方法在 MVTec AD 上的公开报告值，并与本文实测结果并列。需要强调的是，这些文献值取自各自原论文，本文并未重新实现它们；由于骨干网络、输入分辨率、coreset 比例与随机种子等设置存在差异，跨论文数值只能作为量级参照，不宜直接用于严格排名。可以看到，本文复现的基线在像素级指标上与 PatchCore 原文几乎持平（98.12% vs 98.1%），说明复现保真度较高；图像级差距（99.05% vs 99.6%）则主要来自实现细节与聚合方式，这也正是本文改进所针对的环节。

表 4 与代表性方法的对比（15 类平均，%）

方法	图像级 AUROC	像素级 AUROC	说明
SPADE[4]	85.4	87.7	文献值
PaDiM[5]	95.2	94.3	文献值
RD[6]	99.0	98.0	文献值
PatchCore[2]	99.6	98.1	文献值
本文（基线复现）	99.05	98.12	本文实测
本文（C2，$\rho = 0.01$）	99.12	98.12	本文实测

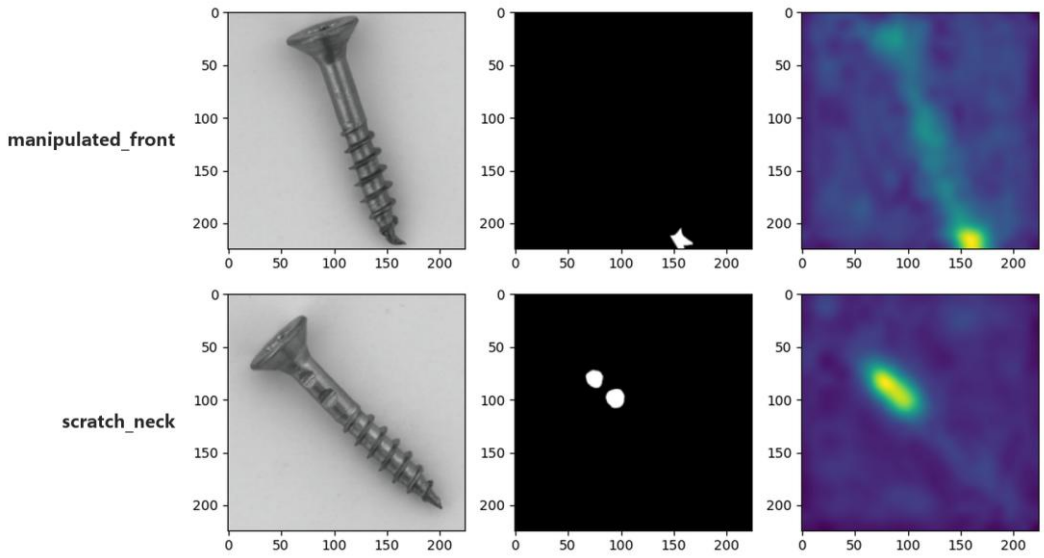


图 2 screw 类别两种缺陷形态（上：manipulated_front；下：scratch_neck）的原图、真值掩码与异常热图（基线方法）。两种形态下热图的高响应区域均与缺陷位置吻合，说明像素级定位准确；而该类图像级 AUROC 仅 98.09%，说明定位能力未能等价转化为判定能力

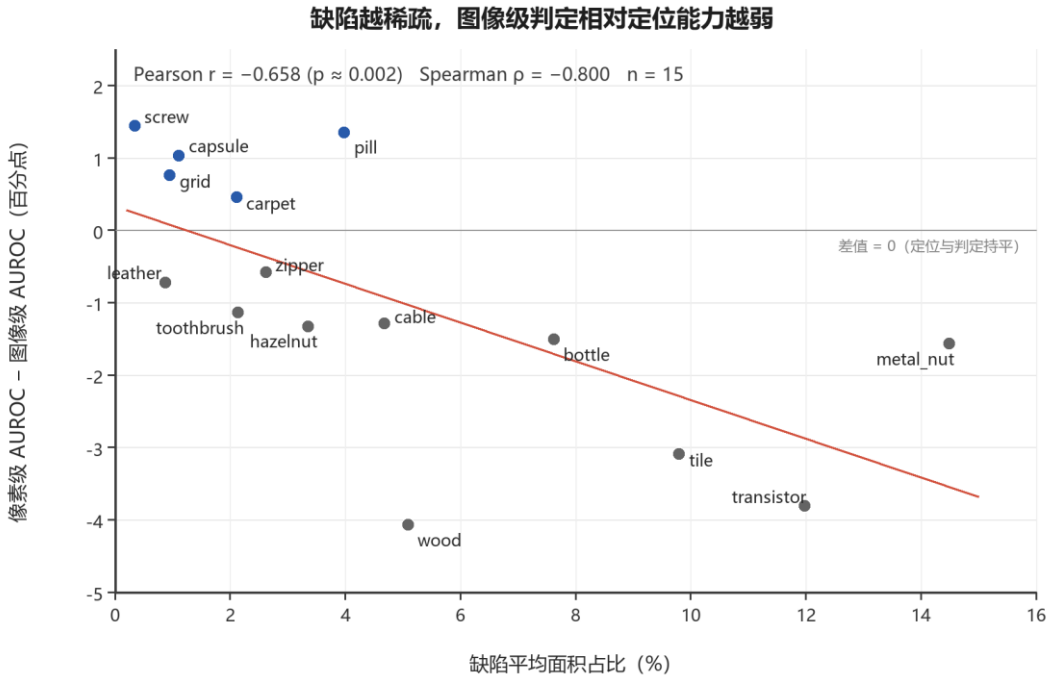


图 3 缺陷平均面积占比与「像素级 − 图像级」AUROC 差值的关系（15 类，红线为最小二乘拟合；蓝色为差值大于 0、即定位优于判定的类别）

5 讨论

缺陷稀疏度是“定位准、判定漏”的量化解释。我们统计了每类缺陷掩码的平均面积占比，并将其与“像素级 AUROC 减图像级 AUROC”的差值做相关分析。结果显示两者显著负相关：Pearson r = −0.658（p ≈ 0.002），Spearman ρ = −0.800，

以对数面积计算时 $r = -0.722$（$p \approx 0.0002$）。具体地，面积最小的 screw（0.34%）、grid（0.95%）、capsule（1.11%）三类的差值均为正（分别为 +1.44、+0.76、+1.03 个百分点），而图像级达到 100% 的 bottle、hazelnut、leather、transistor 四类，其平均缺陷面积分别为 7.62%、3.35%、0.87%、11.98%，除 leather 外均属中等以上。这说明缺陷越稀疏，图像级判定相对定位能力越弱，与本文关于“全局最大聚合被单个 patch 支配”的归因一致。图 3 给出全部 15 类的散点与拟合线。需要指出的是 leather 是明显的离群点（面积小但图像级 100%），其成因可能在于该类纹理均匀、缺陷与背景的对比度极高，单个 patch 即可稳定区分，这也提示面积并非唯一因素，对比度与纹理一致性同样起作用。

改进幅度为何有限，以及聚合方式的边界在哪里。MVTec AD 每类的测试集规模在数十至两百张之间，AUROC 的取值高度离散（如 60 张测试图对应的最小可分辨变化约为 0.3 个百分点），因此 0.1 个百分点量级的改进接近测量噪声的下限。更根本的原因在于基线已接近饱和：15 类中有 4 类的图像级 AUROC 为 100%，平均 99.05%，剩余可用提升空间合计不足 1 个百分点。第 4.4 节的消融进一步给出了聚合方式的适用边界：ρ 过小（趋近最大值）对噪声敏感，ρ 过大则把稀疏缺陷淹没在正常 patch 中，screw 在 $\rho = 1.0$ 时下降超过 20 个百分点即为极端例证。换言之，top-k 聚合是一个有明确最优点、且最优位置随缺陷稀疏度移动的策略，并不存在对所有类别都最优的固定 ρ。本文取 $\rho = 0.01$ 是在 15 类平均意义下的折中，若面向单一部署场景，宜按该类的缺陷面积分布重新标定。我们认为，若要在 MVTec AD 上取得显著提升，需要改变特征表征本身（如多尺度融合、局部对比建模），而非仅调整聚合。

局限性与可复现性。本文仅使用单一骨干（WideResNet50-2）、单一 coreset 比例（$p = 0.1$）与单一随机种子（seed = 0），未报告多次运行的方差；相关性分析基于 15 个类别点，样本量有限，结论宜作趋势性解读而非精确预测。此外，PatchCore 不含可训练参数，所谓“权重”实为各类别的 coreset 记忆库，因而体积较大（15 类约 1 GB），本文通过发布页而非代码仓库分发。为保证可复现性，所有实验均在同一份代码基线上完成，改进由环境变量 PATCHCORE_TOPK_RATIO 控制，取值为 0 时严格退化为原实现；各次运行的完整命令行、逐类指标与记忆库均已随代码一并公开。

6 结论

本文在 MVTec AD 15 类上完整复现了 PatchCore，像素级 AUROC 与原文基本一致，并定位到图像级指标偏低的原因在于全局最大值聚合。据此提出的 top-1% 均值聚合在保持定位能力不变的前提下改善图像级判定，且对已达性能上限的类别无副作用；消融进一步表明聚合比例存在明确的最优点，过大或过小都会显著劣化图像级指标。相关性分析则从统计上印证了“缺陷越稀疏、图像级判定越吃亏”这一判断。实验同时表明，评分聚合是复现链条中一个被低估、却对图像级指标有实质影响的环节，值得在后续工作中系统研究。

参考文献

[1] BERGMANN P, FAUSER M, SATTLER D, et al. The MVTec anomaly detection dataset: a comprehensive real-world dataset for unsupervised anomaly detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2019: 10308-10317.

[2] ROTH K, PEMULA L, ZEPEDA J, et al. Towards total recall in industrial anomaly detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 14318-14328.

[3] ZAVRTANIK V, KRISTAN M, SKOCAJ D. DRAEM: a discriminatively trained reconstruction embedding for surface anomaly detection[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021: 8330-8339.

[4] COHEN N, HOSHEN Y. Sub-image anomaly detection with deep pyramid correspondences[J]. arXiv preprint arXiv:2005.02357, 2020.

[5] DEFARD T, SETKOV A, LOESCH A, et al. PaDiM: a patch distribution modeling framework for anomaly detection and localization[C]//International Conference on Pattern Recognition Workshops. 2021: 475-489.

[6] TIEN T D, NGUYEN A T, LE H, et al. Revisiting reverse distillation for anomaly detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 24511-24520.

[7] LIU Z, ZHOU Y, XU Y, et al. SimpleNet: a simple network for image anomaly detection and localization[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 20402-20411.